데이터 과학 기초

07

텍스트 분석

경북대학교 배준현 교수 (joonion@knu.ac.kr)



○ O7. 텍스트 분석

- 비정형 데이터: *Unstructured* Data
 - 미리 정의된 데이터 모델이 없거나, 미리 정의된 방식으로 정리되지 않은 정보
 - 이미지, 텍스트, 사운드, 동영상, 기타 등등
 - 비정형 데이터의 처리: Embedding
 - 비정형 데이터의 특징을 추출하여 정형 데이터로 바꾸기
 - 이미지 임베딩: ImageNet
 - 텍스트 임베딩: Bag of Words, Word2Vec



○ O7. 텍스트 분석

- 자연어 처리: NLP, Natural Language Processing
 - 자연어: 사람이 일상 생활에서 사용하는 언어
 - 자연어 처리: 번역, 요약, 분류, 감성 분석, 챗봇, 기타 등등
 - 자연어의 구성: 문서, 문장, 단어
 - 문서: 문장들의 집합. Document
 - 문장: 단어들의 집합
 - 단어: 텍스트 분석의 기본 단위. Word = Term



○ 07. 텍스트 분석

- 텍스트 전처리: Text Preprocessing
 - 코퍼스(*Corpus*): 말뭉치. 텍스트 분석을 위한 데이터셋.
 - 텍스트 분석을 위한 전처리 과정:
 - 변환: Transformation
 - 토큰화: Tokenization
 - 정규화: Normalization
 - 필터링: Filtering
 - N-그램: N-grams Range
 - 품사 태깅: POS Tagger



○ 07. 텍스트 분석

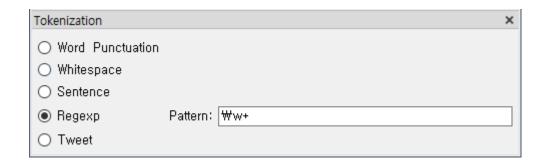
- 변환: Transformation
 - Text Cleansing: 텍스트에서 불필요한 요소를 제거하고 수정.





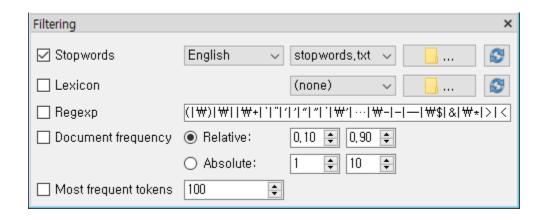
○ O7. 텍스트 분석

- 토큰화: Tokenization
 - 문서에서 문장을 분리, 또는, 문장에서 단어를 분리
 - 정규 표현식: Regular Expression
 - 규칙을 기반으로 토큰을 분리할 수 있음





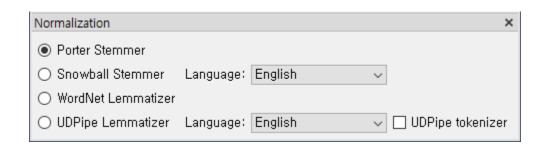
- 필터링: Filtering
 - 불용어 (Stopwords) 처리: 분석에 필요하지 않은 단어를 제거
 - 출현 빈도수가 높은 단어만 선택





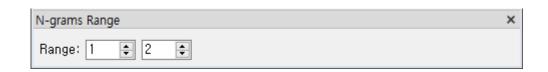
O7. 텍스트 분석

- 정규화: Normalization
 - 형태소 분석: 같은 의미지만 서로 다른 단어들을 하나의 단어로 일반화
 - 어간 추출: Stemming
 - 표제어 추출: Lemmatization





- - N-그램: N-grams Range
 - 분석 결과의 단위를 연속적인 N개의 토큰으로 구성



How are you? Fine, thank you. And you?



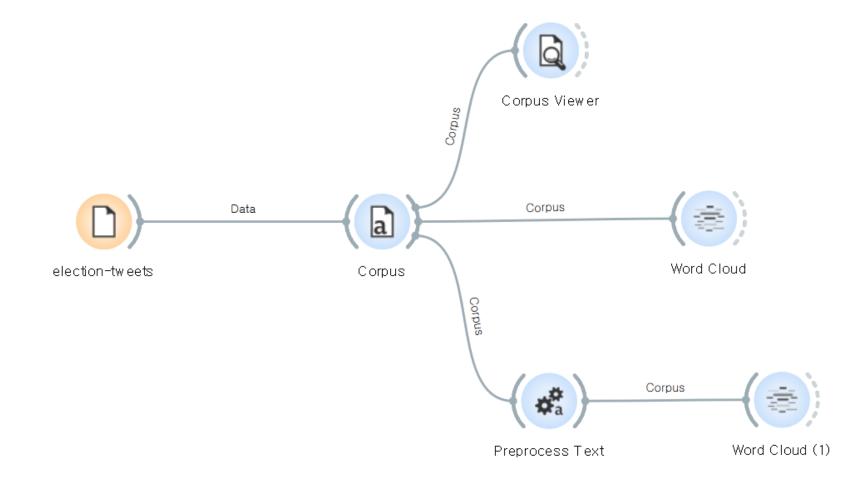
- 품사 태깅: POS(Part-Of-Speech) Tagger
 - 각 단어의 품사를 태그하여 단어의 의미 파악



I believe I can *fly*. Because I am a *fly*.

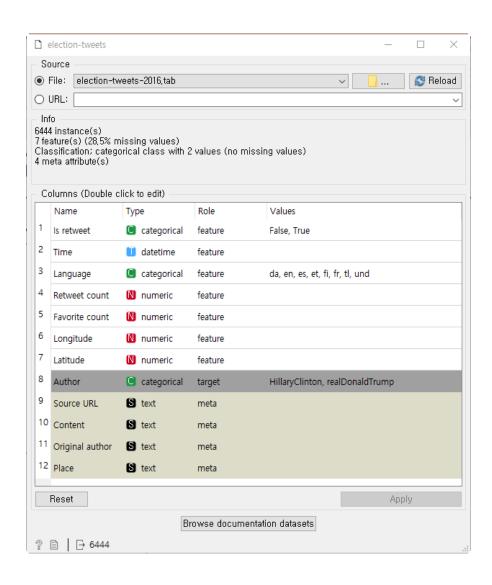


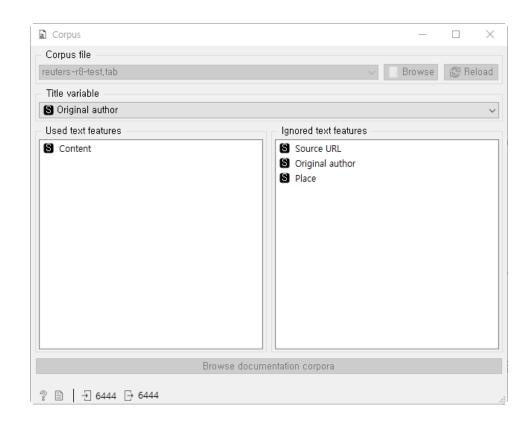
Orange: Text Mining





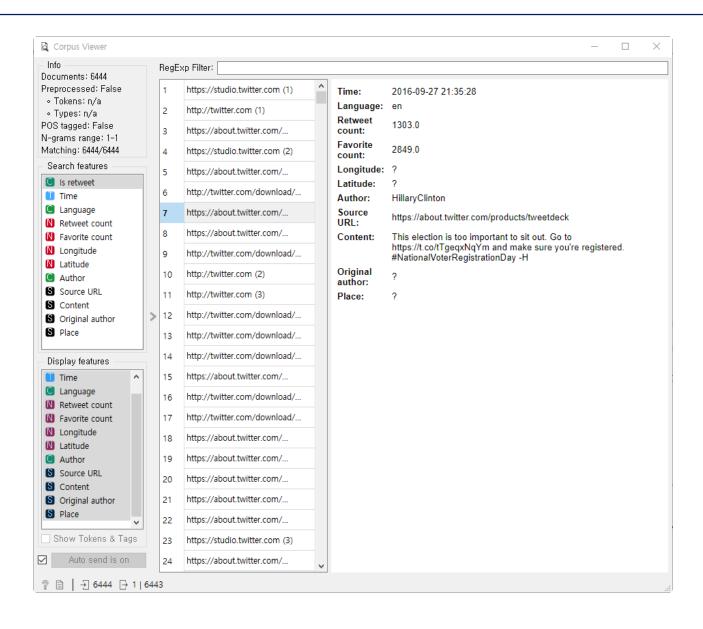
O7. 텍스트 분석



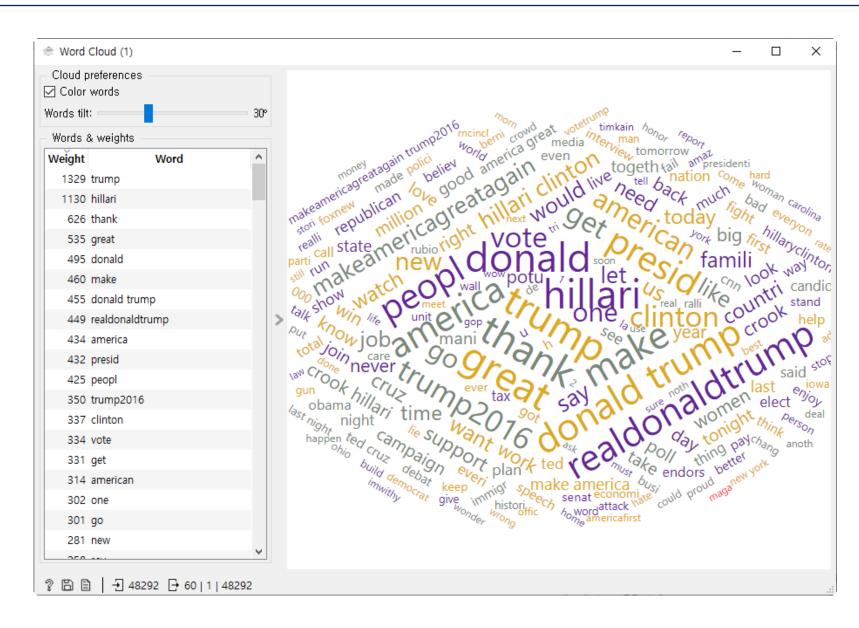




▶ 07. 텍스트 분석



(63)



- 단어 가방: *Bag of Words*, BoW
 - 문서(Document)에 포함되어 있는 단어(Word)의 빈도 수로 특징 추출
 - 순서나 문맥을 무시하고 가방에 단어를 담기 때문에 처리가 간단함

D.1: John likes to watch movies. Mary likes movies too.

D.2: Mary also likes to watch football games.

BoW.1: John:1, likes:2, to:1, watch:1, movies:2, Mary:1, too:1

BoW.2: Mary:1, also:1, likes:1, to:1, watch:1, football:1, games:1



- 단어 빈도: TF, Term Frequency
 - 특정 단어가 문서 내에서 얼마나 자주 등장하는가?

BoW.1: John:1, likes:2, to:1, watch:1, movies:2, Mary:1, too:1

BoW.2: Mary:1, also:1, likes:1, to:1, watch:1, football:1, games:1

	John	likes	to	watch	movies	Mary	too	also	football	games
D.1	1	2	1	1	2	1	1	0	0	0
D.2	0	1	1	1	0	1	0	1	1	1



- 문서-단어 행렬: DTM, Document-Term Matrix
 - 각 문서별로 해당 단어가 몇 번 나타나는가를 표시한 행렬
 - Term Frequency:
 - Count: 단어가 나타나는 횟수로 만드는 경우
 - Binary: 단순하게 단어가 포함되어 있는가의 여부
 - Sublinear: 단어-빈도(TF)의 로그값



- 문서 빈도: DF, Document Frequency
 - 단어의 빈도수만으로 벡터화를 할 경우, 단어의 중요성을 간과하게 됨.
 - **9**1) The anatomy of a large-scale hypertextual web search engine.
 - 특별한 단어에 가중치를 주는 방법: 단어의 희소성을 고려
 - 개별 문서에 자주 나타나는 단어는 높은 가중치를 주되,
 - 모든 문서에 전반적으로 자주 나타나는 단어에 대해서는 페널티를 부여.
 - Document Frequency:
 - IDF: Inverse Document Frequency
 - Smooth IDF: Divide-by-Zero 방지를 위해 DF에 1을 더한 값을 사용



- *TF-IDF*: Term Frequency Inverse Document Frequency
 - 텍스트 마이닝과 정보 검색에서 많이 이용하는 가중치 부여 방법
 - TF-IDF는 단어 빈도(TF)와 역 문서 빈도(IDF)를 곱한 값
 - 전체 문서를 D, 문서를 d, 단어를 t라 할 때
 - TFIDF(t,d,D) = TF(t,d) * IDF(t,D)
 - $TF(t,d) = 0.5 + \frac{0.5 \times f(t,d)}{\max\{f(w,d): w \in d\}}$
 - $IDF(t,D) = \log \frac{|D|}{|\{d \in D: t \in d\}|}$

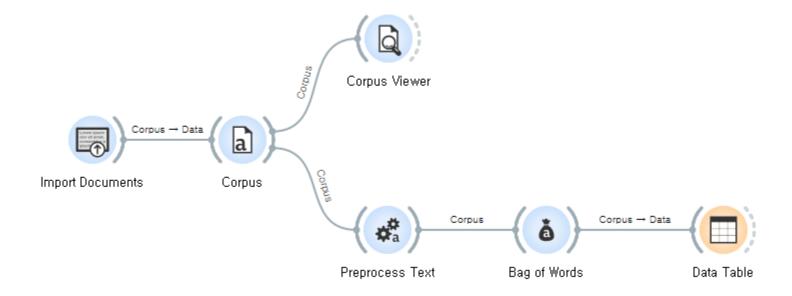


■ 단어 가방의 한계:

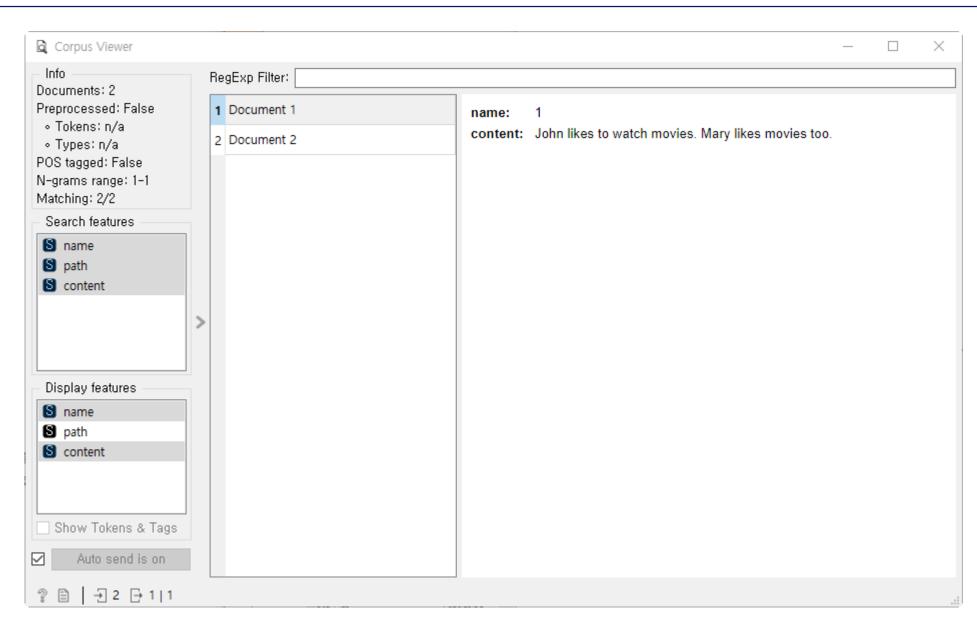
- 희소 행렬: Sparse Matrix
 - 많은 문서에서 많은 단어를 추출하면 단어 집합의 크기가 커지고,각 문서에 포 함된 단어의 수는 일정하므로, 매우 큰 희소 행렬이 됨.
 - 희소 행렬의 연산에 적절한 행렬 처리가 필요함
- 문맥과 의미: Contexts and Semantics
 - BoW는 단어의 순서를 고려하지 않으므로 문맥적 의미를 무시함.
 - 단어와 문장의 순서를 고려하여 문맥과 의미를 반영할 필요가 있음.



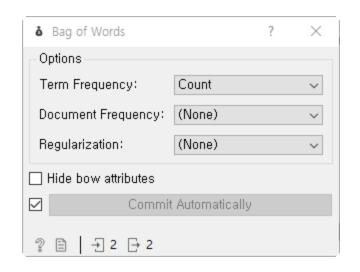
Orange: Bag of Words











{...}

john=1, likes=2, mary=1, movies=2, to=1, too=1, watch=1 also=1, football=1, games=1, likes=1, mary=1, to=1, watch=1

{...}

john, likes, mary, movies, to, too, watch also, football, games, likes, mary, to, watch

{...}

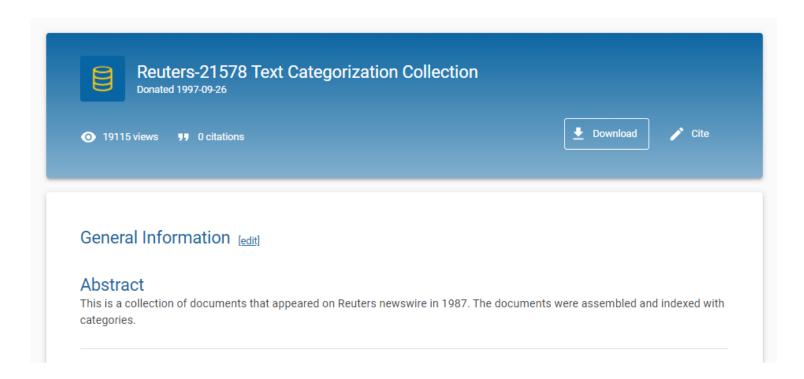
john=0.693147, movies=1.38629, too=0.693147 also=0.693147, football=0.693147, games=0.693147



- 텍스트 분류: Text *Classification*
 - 주어진 문서를 특정 카테고리로 분류하는 기법
 - 예) 뉴스 기사 자동 분류, 스팸 메일 필터링.



- Dataset: reuters-r8-train.tab
 - 원본: UCI M/L Repository
 - Reuters-21578 Text Classification Collection
 - https://archive-beta.ics.uci.edu/ml/datasets/137





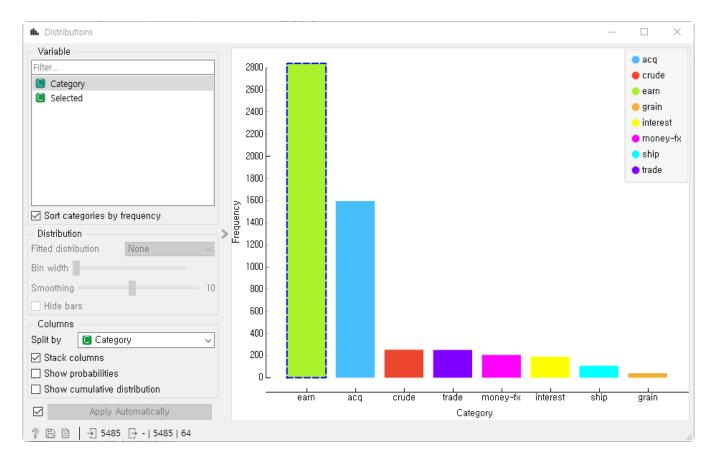
■ 데이터 탐색:

- Reuters-R8: 로이터의 뉴스기사 모음. R8은 전체 중 8개의 섹션만 모음.
- About the preprocessing:
 - Substitute TAB, NEWLINE and RETURN characters by SPACE.
 - Keep only letters: punctuation, numbers are removed.
 - Turn all letters to lowercase.
 - Substitute multiple SPACES by a single SPACE.
 - The title/subject of each document is simply added in the beginning of the document's text.

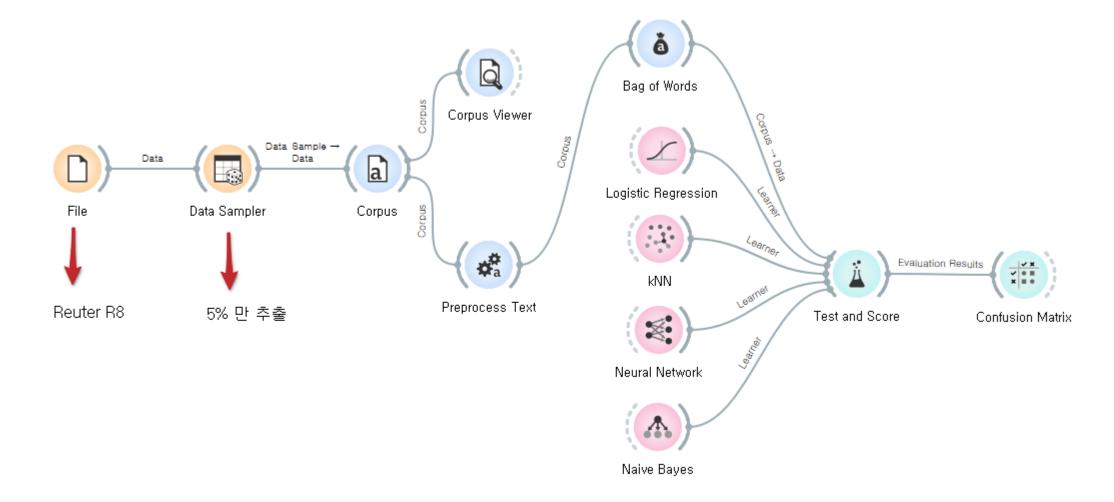


■ 데이터 탐색:

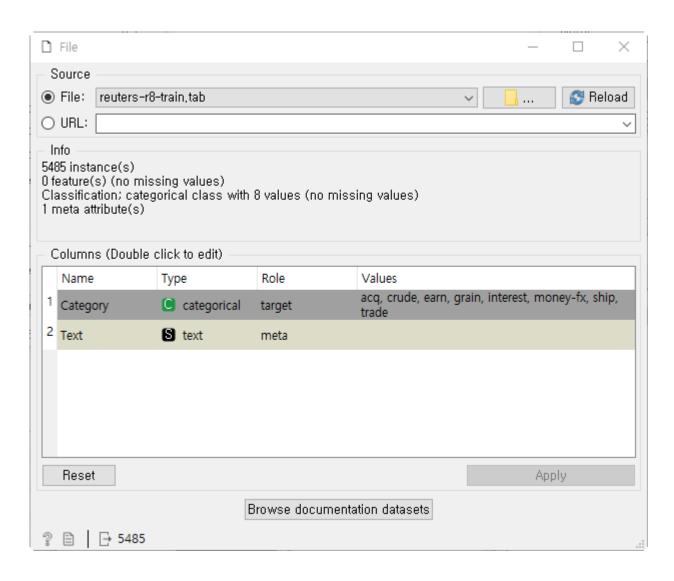
- 총 5,485개의 기사: 총 8개의 섹션
 - earn, acq, crude, trade, money-fx, interest, ship, gain



■ 로이터 기사 섹션 분류기:

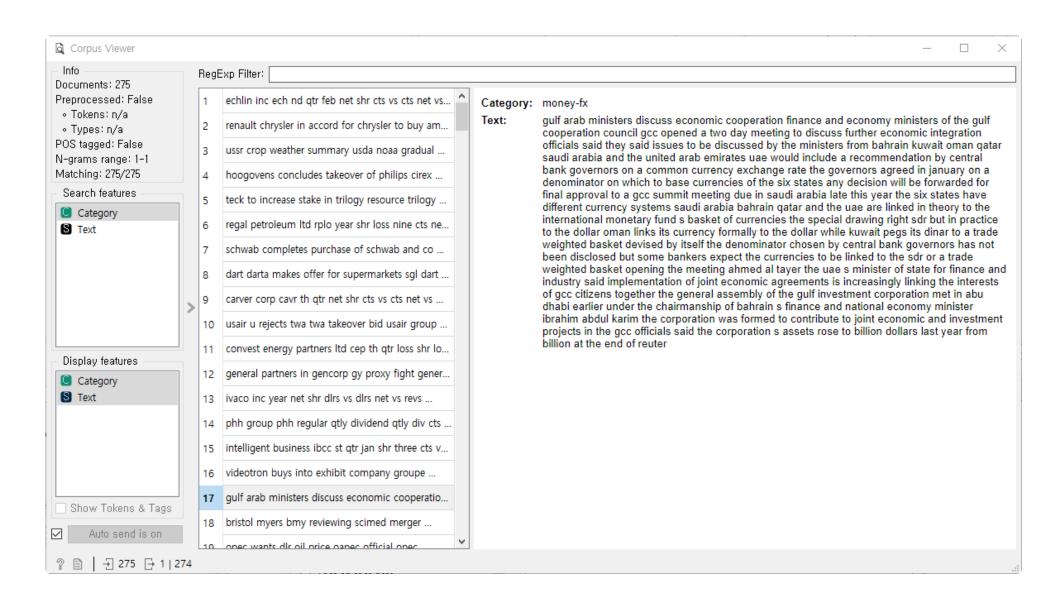






□ Data Sampler ? ×					
Sampling Type • Fixed proportion of data:					
5%					
O Fixed sample size					
Instances: 1					
Sample with replacement					
Cross validation					
Number of subsets: 10					
Unused subset: 1					
○ Bootstrap					
Options					
☐ Replicable (deterministic) sampling					
✓ Stratify sample (when possible)					
Sample Data					
② 🗎 │ 🛨 5485 🕞 275 5210					







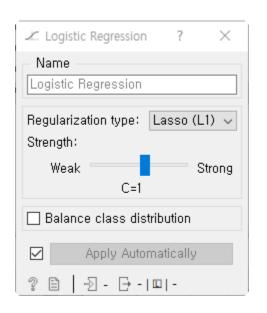
○ O7. 텍스트 분석

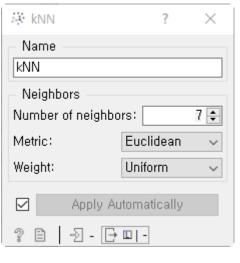
₡ Preprocess Text		- C X
Preprocessors		Transformation × ^
HH Transformation Tokenization Normalization Filtering N-grams Range		✓ Lowercase ✓ Remove accents ✓ Parse html ✓ Remove urls
Preview echlin, inc, ech, nd, qtr	>	Tokenization × Word Punctuation Whitespace Sentence Regexp Pattern: \ww+
		Stopwords
Apply Automatically		
? 🗎 → 275 🕞 275		

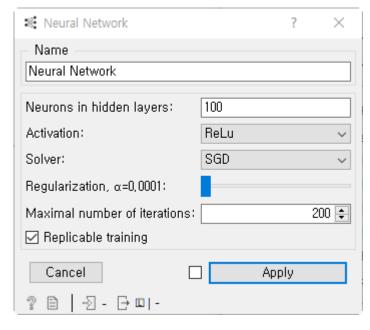
& Bag of Words	? ×						
Options							
Term Frequency: Co	ount ~						
Document Frequency: ID	F ~						
Regularization: (N	one) ~						
☐ Hide bow attributes							
☑ Commit Au	Commit Automatically						
② ☐ ☐ 275 ☐ 275							

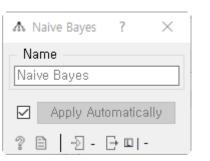


> 07. **텍스트 분석**

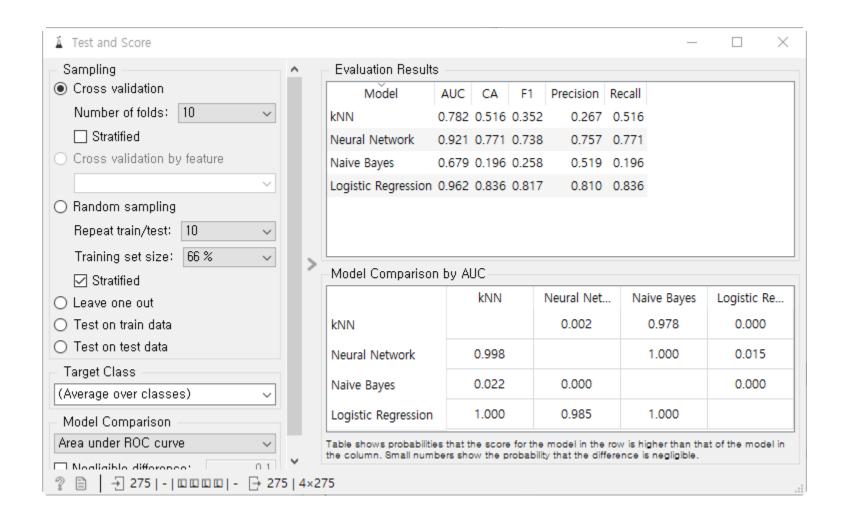










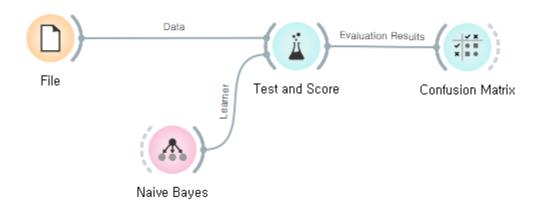








- 나이브 베이지안 분류기: Naïve Bayesian Classifier
 - 특징변수(feature)가 서로 독립사건이라는 순진한 가정하에
 - 베이즈 정리를 적용하여 확률적으로 목적변수(target)를 추론하는 분류기
 - 예) 스팸 메일 분류기, 암 진단





○ O7. 텍스트 분석

- 확률: Probability
 - 시행, 사건, 확률: trial, event, and probability
 - 시행 = 동전 던지기, 사건의 집합: $S = \{H, T\}$
 - 확률: P(H) = 동전 던지기를 했을 때, 앞면(H)이 나올 확률
 - 사건: 상호배타적이고 포괄적(*mutually exclusive* and *exhaustive*)

○ O7. 텍스트 분석



- 결합 확률: *Joint* Probability
 - $P(A \cap B)$: 두 사건 A와 B가 동시에 일어날 확률
 - 독립 사건: *Independent* Events
 - 사건 A가 일어나는 것과 무관하게 사건 B가 일어나는 경우
 - 예) A: 동전의 앞면이 나오는 사건, B: 주사위의 짝수가 나오는 사건
 - 종속 사건: *Dependent* Events
 - 두 사건 A와 B가 독립사건이 아닌 경우
 - 예) A: 주사위의 홀수가 나오는 사건, B: 주사위의 소수가 나오는 사건
 - 두 사건 A, B가 독립사건일 경우:
 - $-P(A \cap B) = P(A) \times P(B)$



- 조건부 확률: *Conditional* Probability
 - P(A|B): 사건 B가 발생한 경우, 사건 A가 발생할 확률
 - 두 사건 A와 B가 독립사건이라면,

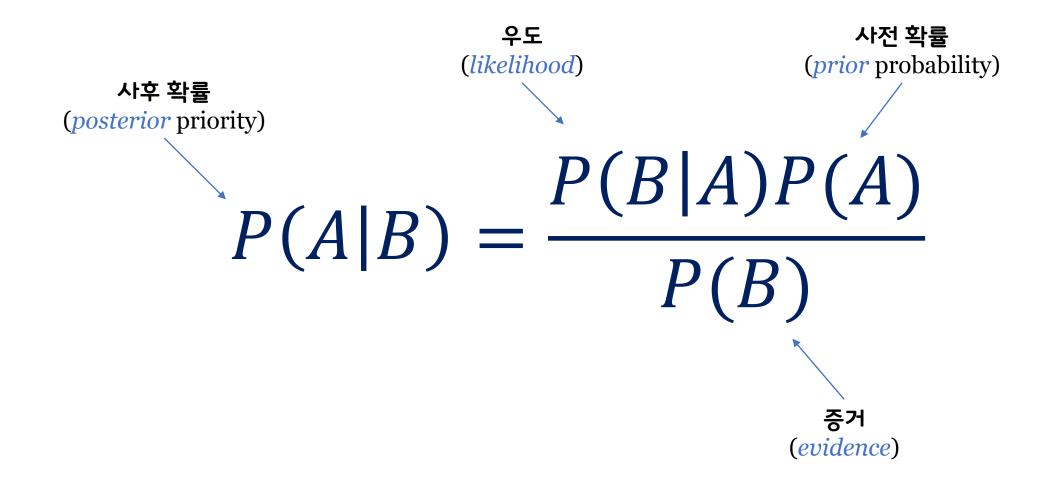
$$- P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$- P(B|A) = \frac{P(A \cap B)}{P(A)}$$

- CC+2+M, $P(A|B) \times P(B) = P(B|A) \times P(A)$



■ 베이즈 정리: Bayes Theorem



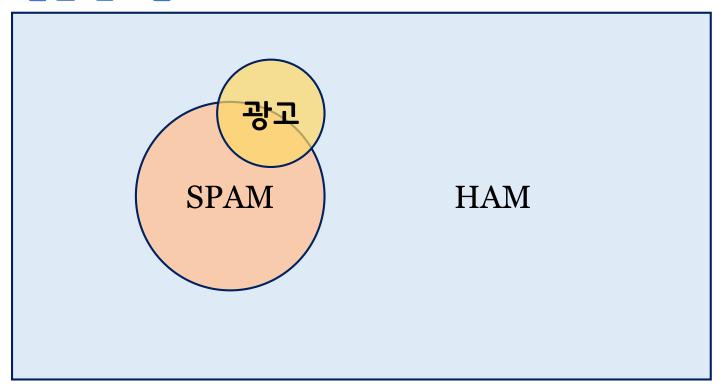


■ 스팸 메일 분류기 만들기:

SPAM? or HAM?



받은 편지함





○ 07. 텍스트 분석

■ 과거 데이터로부터의 학습:

• 빈도표와 우도표: frequency table and likelihood table

	"광고"		
	포함	불포함	
SPAM	4	16	20
НАМ	1	79	80
	5	95	100

	"광고"		
	포함	불포함	
SPAM	4/20	16/20	20/100
НАМ	1/80	79/80	80/100
	5/100	95/100	1





- 베이즈 정리의 적용:
 - "광고"라는 단어가 들어간 메일이 스팸일 확률은?

$$P(SPAM| 광고) = \frac{P(광고|SPAM)P(SPAM)}{P(광고)}$$
$$= \frac{4/20 \times 20/100}{5/100} = 0.80$$



- 나이브 베이지안 알고리즘:
 - 매우 순진한 가정: 사전 확률을 구성하는 사건은 모두 독립사건이다.
 - 만약, 내가 받은 이메일에 다음과 같은 단어들이 포함되었다면?
 - 광고 (W_1) , 자기야 (W_2) , 사랑해 (W_3) , 폭탄 세일 (W_4)

$$P(SPAM|W_1 \cap \neg W_2 \cap \neg W_3 \cap W_4) = \frac{P(W_1 \cap \neg W_2 \cap \neg W_3 \cap W_4|SPAM)P(SPAM)}{P(W_1 \cap \neg W_2 \cap \neg W_3 \cap W_4)}$$

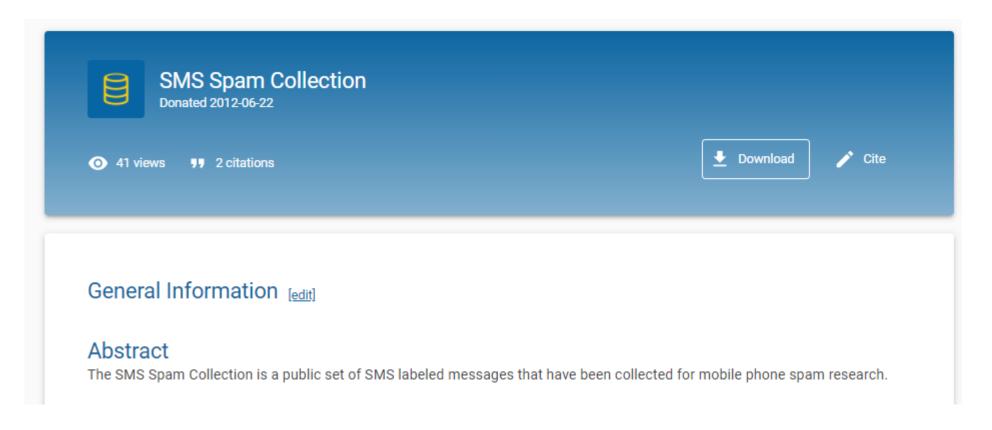
$$= \frac{P(W_1|SPAM)P(\neg W_2|SPAM)P(\neg W_3|SPAM)P(W_4|SPAM)P(SPAM)}{P(W_1 \cap \neg W_2 \cap \neg W_3 \cap W_4)}$$



- 나이브 베이지안 분류기:
 - 사후 확률을 통해서 해당 사건이 발생할 것인지 여부를 예측
 - 예) 스팸 메일일 확률이 90%, 암 환자일 확률이 98%
 - 순진하고, 때로는 잘못된 가정을 했음에도 불구하고 우수한 성능을 보임



- Dataset: SMS Spam Collection
 - 원본: UCI M/L Repository
 - https://archive-beta.ics.uci.edu/ml/datasets/228



■ R에서 스팸 필터 만들기:

```
## 2. 워드 클라우드 보기

# word cloud visualization
library(wordcloud)
wordcloud(sms_corpus_clean, min.freq = 50, random.order = FALSE)

spam <- subset(sms_raw, type == "spam")
ham <- subset(sms_raw, type == "ham")

wordcloud(spam$text, max.words = 40, scale = c(3, 0.5))
wordcloud(ham$text, max.words = 40, scale = c(3, 0.5))
```

> 07. 텍스트 분석

```
## 3. 텍스트 전처리

# build a corpus using the text mining (tm) package
library(tm)
sms_corpus <- VCorpus(VectorSource(sms_raw$text))
sms_corpus

# clean up the corpus using tm_map()
sms_corpus_clean <- tm_map(sms_corpus, content_transformer(tolower))
sms_corpus_clean <- tm_map(sms_corpus_clean, removeNumbers) # remove numbers
sms_corpus_clean <- tm_map(sms_corpus_clean, removeWords, stopwords()) # remove stop words
sms_corpus_clean <- tm_map(sms_corpus_clean, removePunctuation) # remove punctuation
```

```
# illustration of word stemming
library(SnowballC)
wordStem(c("learn", "learned", "learning", "learns"))
sms corpus clean <- tm map(sms corpus clean, stemDocument)</pre>
sms_corpus_clean <- tm_map(sms_corpus_clean, stripWhitespace) # eliminate whitespaces</pre>
# examine the final clean corpus
lapply(sms_corpus[1:3], as.character)
lapply(sms_corpus_clean[1:3], as.character)
# create a document-term sparse matrix
sms_dtm <- DocumentTermMatrix(sms_corpus_clean)</pre>
```

```
> lapply(sms_corpus[1:3], as.character)
$`1`
[1] "Hope you are having a good week. Just checking in"
$`2`
[1] "K...give back my thanks."
$`3`
[1] "Am also doing in cbe only. But have to pay."
> lapply(sms_corpus_clean[1:3], as.character)
$`1`
[1] "hope good week just check"
$`2`
[1] "kgive back thank"
$`3`
[1] "also cbe pay"
```



```
## 4. 훈련용/시험용 데이터 준비
# creating training and test datasets
sms dtm train <- sms dtm[1:4169, ]</pre>
sms dtm test <- sms dtm[4170:5558, ]
# also save the labels
sms train labels <- sms raw[1:4169, ]$type
sms_test_labels <- sms_raw[4170:5558, ]$type</pre>
# check that the proportion of spam is similar
prop.table(table(sms_train_labels))
prop.table(table(sms_test_labels))
sms_dtm_freq_train <- removeSparseTerms(sms_dtm_train, 0.999)</pre>
sms dtm freq train
```



```
# save frequently-appearing terms to a character vector
sms freq words <- findFreqTerms(sms dtm train, 5)</pre>
str(sms freq words)
# create DTMs with only the frequent terms
sms dtm freq train <- sms dtm train[ , sms freq words]</pre>
sms dtm freq test <- sms dtm test[ , sms freq words]</pre>
# convert counts to a factor
convert counts <- function(x) {</pre>
  x \leftarrow ifelse(x > 0, "Yes", "No")
# apply() convert counts() to columns of train/test data
sms train <- apply(sms dtm freq train, MARGIN = 2, convert counts)</pre>
sms test <- apply(sms dtm freq test, MARGIN = 2, convert counts)</pre>
```

O7. 텍스트 분석

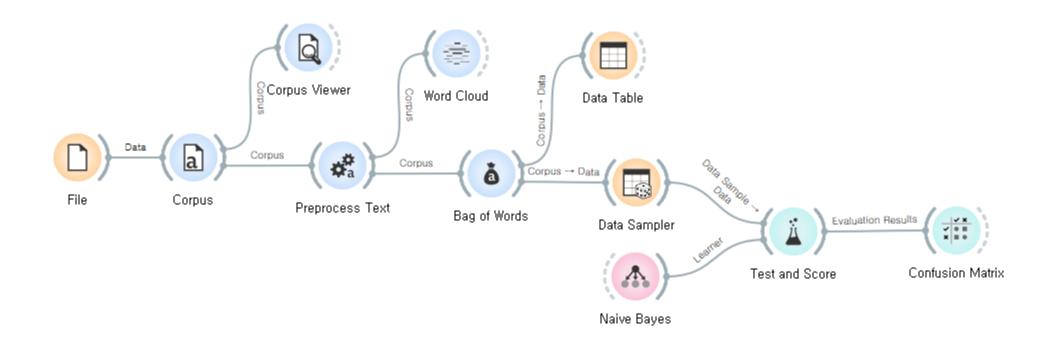
```
## 5. 나이브 베이지안 분류기 적용
library(e1071)
sms_classifier <- naiveBayes(sms_train, sms_train_labels)</pre>
sms_test_pred <- predict(sms_classifier, sms_test)</pre>
## 6. 혼동 행렬 출력하기
library(gmodels)
CrossTable(sms_test_pred, sms_test_labels,
           prop.chisq = FALSE, prop.c = FALSE, prop.r = FALSE,
           dnn = c('predicted', 'actual'))
```

Total Observations in Table: 1389

	actual			
predicted	ham	spam	Row Total	
ham	1200	30	1230	
	0.864	0.022		
spam	6	153	 159	
	0.004	0.110		
Column Total	1206	183	1389	

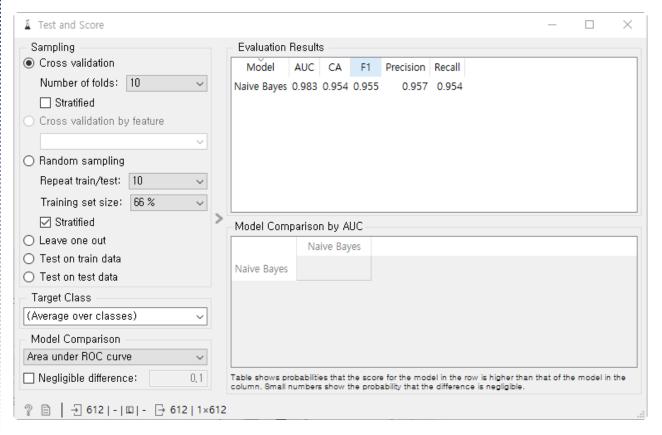


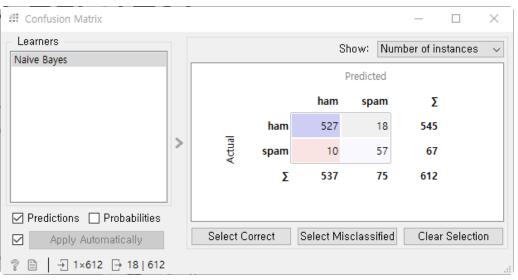
Orange에서 스팸 필터 만들기:





O7. 텍스트 분석







■ 오피니언 마이닝과 감성 분석:

Opinion Mining & Sentiment Analysis

- 문서의 감정을 긍정/중립/부정 등으로 파악하기 위한 방법
- 소셜 미디어, 온라인 리뷰, 영화 댓글 분석 등에 다양하게 활용

Sentiment Analysis



"I am happy with this water bottle."



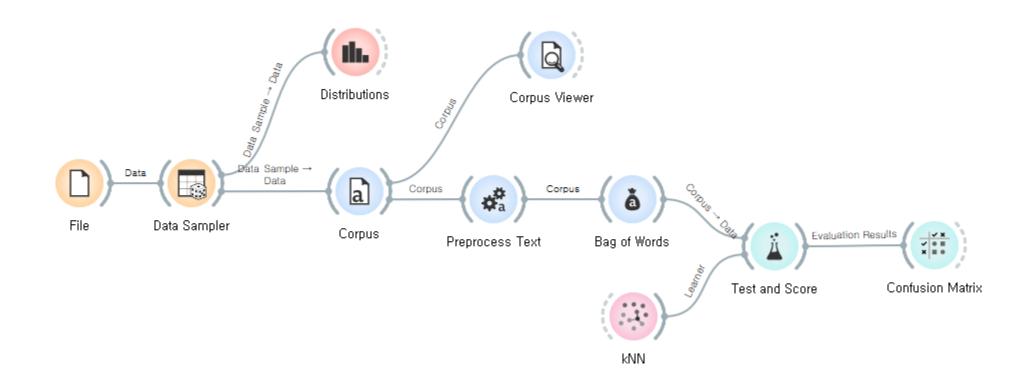
"This is a bad investment."



"I am going to walk today."



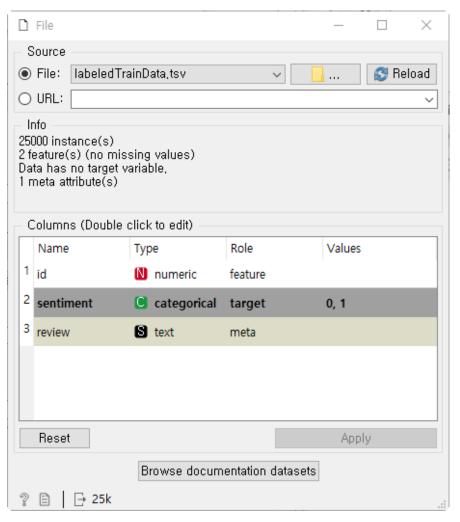
- 감성 분석을 위한 지도 학습:
 - 학습 데이터에 긍정/부정/중립 등의 라벨이 포함되어 있음
 - 기존의 텍스트 기반 분류 알고리즘과 동일한 방법으로 분석 가능함

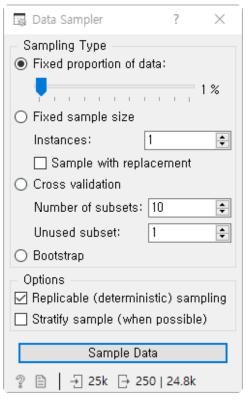


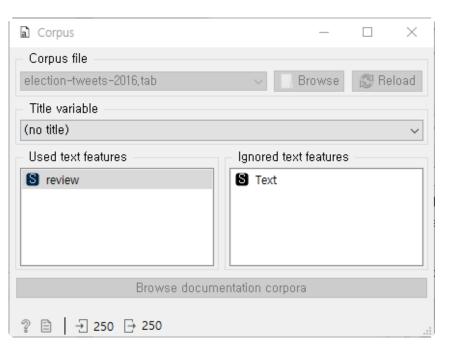


- Dataset: 캐글 IMDB 영화 리뷰 데이터셋
 - Bag of Words Meets Bags of Popcorn
 - https://www.kaggle.com/c/word2vec-nlp-tutorial/data
 - 총 50000개의 IMDB 영화 리뷰에 대한 데이터셋
 - 3개의 변수: id, sentiment(target), review(text)
 - sentiment: 1 for positive, 0 for negative
 - labeledTrainData.tsv

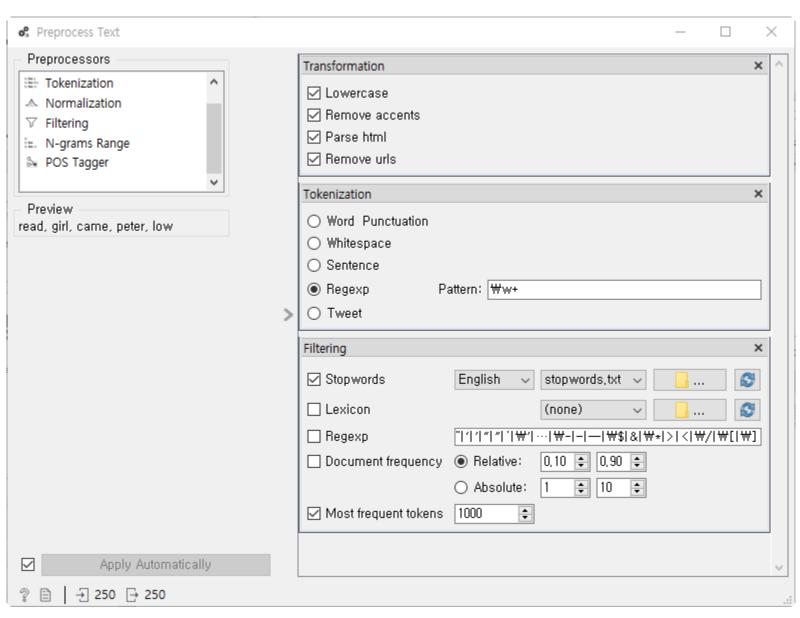








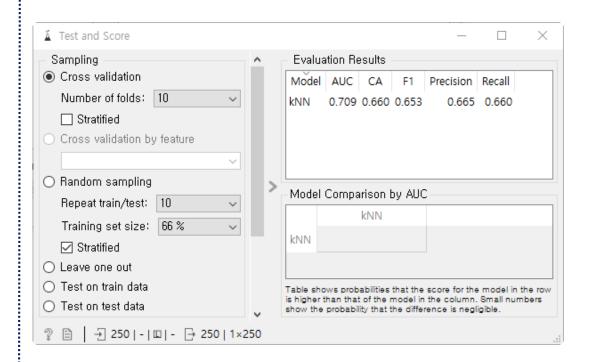


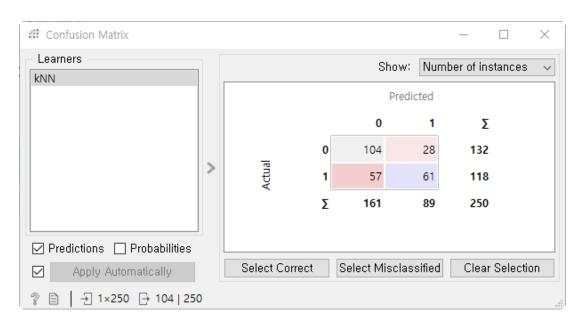


å Bag of Words		?	×		
Options					
Term Frequency:	Count		~		
Document Frequency:	IDF		~		
Regularization:	(None)		~		
☑ Hide bow attributes					
Commit Automatically					
② ☐ ☐ 250 ☐ 250					



O7. 텍스트 분석

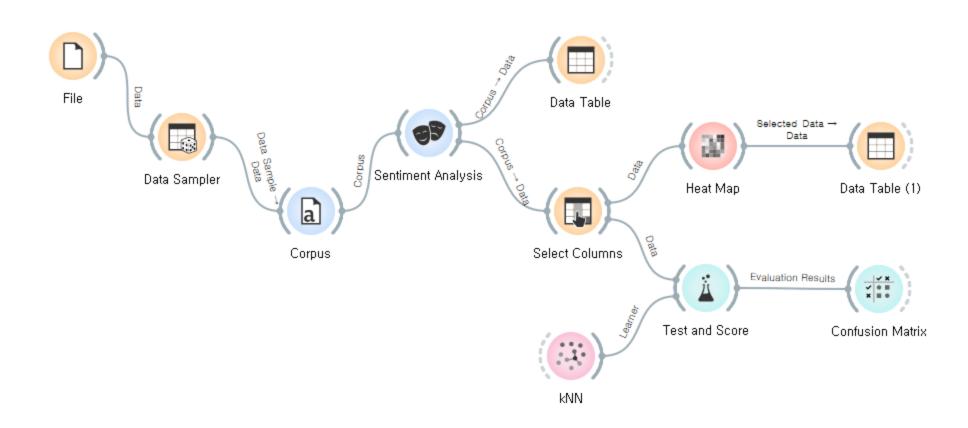


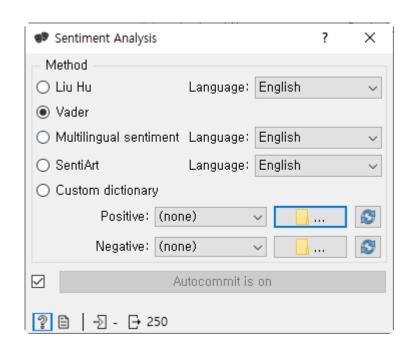


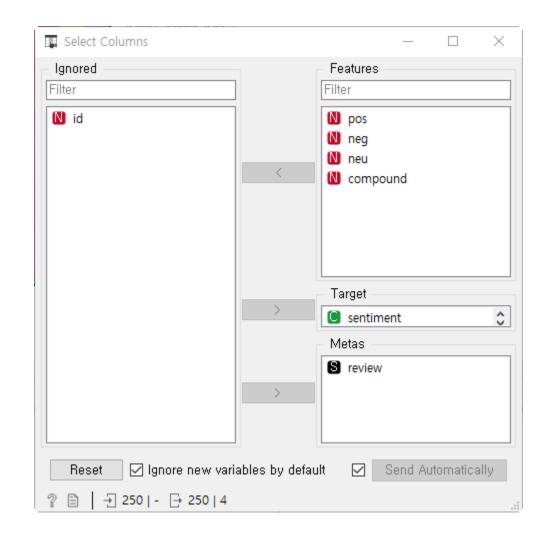
○ O7. 텍스트 분석

- 감성 분석을 위한 비지도 학습:
 - 어휘 사전(Lexicon)을 기반으로 텍스트의 감성을 분석
 - 감성 지수(극성 점수): *Polarity Score*
 - 부정(-1)에서 긍정(+1)까지, 감성의 정도를 의미하는 점수
 - 단어의 위치, 주변 단어, 문맥, 품사(POS) 등을 고려해서 점수 부여
 - 감성 분석을 위한 라이브러리:
 - Liu-Hu: NLTK에 포함된 Lexicon 기반의 감성 분석 모듈
 - VADER: 소셜 미디어의 텍스트에 특화된 감성 분석 모듈
 - SentiArt: VSM(Vector Space Model) 기반의 감성 분석 모듈

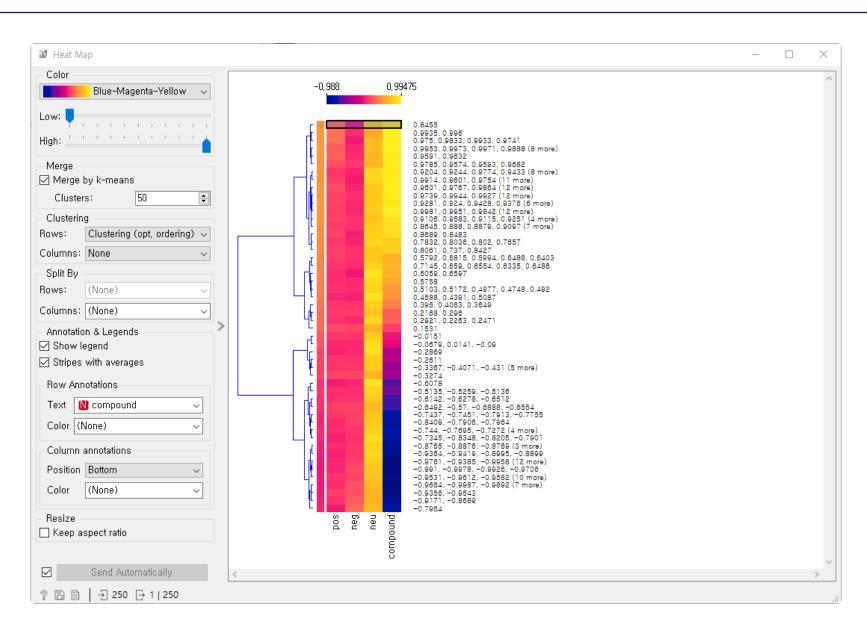












Any Questions?

